



EXAMEN PARCIAL: DEEP LEARNING

Regularización, Optimización y Redes Convolucionales (CNN)

Instrucciones: Lee cada pregunta con cuidado. No se permite el uso de internet ni apuntes. Justifica tus respuestas cuando se indique.

I

Preguntas de Selección Múltiple

P1

¿Cuál de las siguientes afirmaciones describe correctamente el OVERFITTING en una red neuronal?

- a) El modelo tiene un error alto tanto en entrenamiento como en validación.
- b) El modelo aprende los datos de entrenamiento tan bien que falla al generalizar a datos nuevos.**
- c) El optimizador no converge durante el entrenamiento.
- d) La red neuronal tiene muy pocas capas para aprender el problema.

P2

Al usar Regularización L2 (Ridge) en una red neuronal, ¿qué efecto produce en los pesos del modelo?

- a) Fuerza exactamente a cero algunos pesos, produciendo modelos dispersos.
- b) Penaliza los pesos grandes haciéndolos más pequeños, pero rara vez exactamente cero.**
- c) Aumenta los pesos para mejorar la capacidad del modelo.
- d) No tiene efecto si la tasa de aprendizaje es muy pequeña.

P3

¿Qué hace el mecanismo de Dropout durante el entrenamiento?

- a) Elimina neuronas con pesos pequeños de forma permanente.
- b) Detiene el entrenamiento cuando la pérdida deja de mejorar.
- c) Desactiva aleatoriamente una fracción de neuronas en cada paso, forzando redundancia.**
- d) Normaliza las activaciones de cada capa para estabilizar el entrenamiento.

P4

¿Cuál es la principal ventaja del optimizador Adam frente a SGD estándar?

- a) Adam usa una tasa de aprendizaje fija para todos los parámetros.**



- b) Adam adapta la tasa de aprendizaje para cada parámetro usando estimaciones de primer y segundo momento.**
- c) Adam garantiza siempre encontrar el mínimo global.
- d) Adam no requiere ajustar ningún hiperparámetro.

P5

)

En una CNN, ¿cuál es la función principal de una capa de Pooling?

- a) Aumentar la dimensionalidad del mapa de características.
- b) Aprender filtros para detectar patrones locales en la imagen.
- c) Reducir las dimensiones espaciales del mapa de características, disminuyendo cómputo.**
- d) Conectar todas las neuronas de la capa anterior con las de la siguiente.

II

Preguntas de Verdadero / Falso con justificación

Indica V (Verdadero) o F (Falso) y justifica brevemente tu respuesta en 1-2 oraciones.

P6

"La Regularización L1 tiende a producir modelos con pesos dispersos (muchos pesos en cero), lo que puede ser útil para selección de características."

V / F (encierra): Justificación:

Cierto, L1 penaliza la suma de valores absolutos de los pesos. Esto hace que muchos de los coeficientes sean 0. Esto genera modelos dispersos o esparsos esto ayuda a eliminar características poco relevantes y facilita la selección e interpretabilidad de las variables

P7

"ResNet introduce conexiones residuales (skip connections) para resolver el problema del desvanecimiento del gradiente en redes muy profundas."

V / F (encierra): Justificación:

Cierto, esto opera como un refresco de la memoria lo que ayuda a que pueda seguir profundizando sin olvidar lo que aprendió en capas anteriores



--	--

P8 "El Transfer Learning consiste en entrenar una red desde cero usando pesos aleatorios para cada nuevo problema."

V / F (encierra): Justificación: En transfer learning, partimos de una red que cuenta con un aprendizaje general para ajustarlos hacia los requerimientos de un problema usualmente mas especifico. Ello implica usar los pesos que representaban dicho aprendizaje y ajustarlos (en todas las capas o solo en las finales) para que puedan solucionar un nuevo problema

P9 "Batch Normalization normaliza las activaciones de cada mini-batch, lo que permite usar tasas de aprendizaje más altas y acelera la convergencia."

V / F (encierra): Justificación:

III

Emparejamiento

Relaciona cada concepto de la columna izquierda con su descripción correcta en la columna derecha.

A. Momentum (SGD)	2	1. Divide el gradiente por la raíz cuadrada de su promedio cuadrático, adaptando la tasa.
B. RMSProp	1	2. Acumula una fracción del gradiente anterior para suavizar las actualizaciones.
C. LeNet	4	3. Primera CNN profunda ganadora de ImageNet (2012), usó ReLU y Dropout.
D. VGG	5	4. Red de 1998 para reconocimiento de dígitos escritos a mano (MNIST).



E. AlexNet

3

5. Arquitectura de bloques 3x3 muy profunda; demostró que la profundidad importa.

IV

Preguntas de Desarrollo Corto

P10

Explica la diferencia entre Regularización L1 y L2. ¿En qué situación práctica preferirías usar L1 sobre L2? Menciona al menos dos diferencias concretas.

L1 penaliza la suma de los valores absolutos de los pesos, L2 la suma de los pesos. L1 convierte los coeficientes a 0, L2 los hace próximos a 0.

Con L1 y los coeficientes en 0 gano interpretabilidad y ello me permite abordar problemas no lineales en los que considere que algunas de mis variables pueden ser ruido.

Con L2 y los coeficientes cerca a 0, busco capturar la parte de ese ruido que pueda ser útil (o no) para modelar mejor el problema, ello implica un mejor rendimiento, necesidad mayor de datos y mayor dificultad en diferenciar lo que es ruido.

P11

Describe la arquitectura general de una CNN para clasificación de imágenes en CIFAR-10. Incluye en tu respuesta: (a) tipos de capas y su orden típico, (b) el papel de Batch Normalization, y (c) cómo se decide el número de neuronas en la capa Fully Connected final.

Capas convolucionales para sacar bordes texturas y formas.

F. Activación (relu usualmente) para introducir la no linealidad

Batch N, , para normalizar las activaciones intermedias y acelerar el entrenamiento

Maxpooling2d para reducir el tamaño espacial de las características



A veces un dropout para desactivar neuronas aleatoriamente y reducir el overfitting
Flatten para convertir los mapas en un unico vector unidimensional

Capas Fully Connected, penultima capa que permite combinar características aprendidas para realizar la clasificación

Capa Salida o capa softmax, es una capa obligatoria (de facto) ya que traduce la fully connected a una interpretación probabilística de cada clase

EL NUMERO DE CAPAS DE LA FULLY CONNECTED SE DEFINE COMO EL NUMERO DE CLASES A PREDECIR Y DEBE COINCIDIR CON LA CAPA DE SALIDA O SOFTMAX (aunque esta ultima se puede obviar no hay razones para hacerlo)

P12

Tienes un modelo VGG16 preentrenado en ImageNet y quieres usarlo para clasificar imágenes de 10 categorías del dataset Fashion-MNIST (Kaggle). Describe el proceso de Transfer Learning que seguirías: ¿qué capas congelas, qué capas reemplazas y por qué?

Congelo todo menos la ultima capa (esperaria que imagenet ya pueda reconocer un numero) y que solo tuviera que reentrenar la ultima capa para la clasificación de los mismos.

Para este ocr numerico, primero pasaria el mnist por imagenet sin TL.

Capturaria las metricas, congelaria, reentrenaria compararia las metricas veria cual es la mejora y si la hay hemos acabado.

Caso contrario descongelo una capa mas. En caso no mejore (lo cual seria muy raro), ya descongelo todas las capas menos la primera. (si no mejora, seguro estoy haciendo algo tremendamente mal)

**P13**

Analiza el siguiente fragmento de código Python/Keras. Identifica: (a) qué técnica de regularización se usa y en qué capa, (b) qué optimizador se configura y cuáles son sus hiperparámetros, y (c) qué problema podría presentar este modelo con datos de entrenamiento muy pequeños y cómo lo resolverías.

```
model = Sequential([
    Conv2D(64, (3,3), activation='relu', padding='same'),
    BatchNormalization(),
    MaxPooling2D(2,2),
    Dropout(0.4),
    Flatten(),
    Dense(128, activation='relu',
         kernel_regularizer=l2(0.01)),
    Dense(10, activation='softmax')
])
model.compile(
    optimizer=Adam(learning_rate=0.001,
                   beta_1=0.9, beta_2=0.999),
    loss='categorical_crossentropy',
    metrics=['accuracy'])
```

Respuesta:

a; Usa L2 con dropout, esta desactivando aleatoriamente algunas neuronas y esta buscando que sus coeficientes queden cerca a 0

b: Configura un optimizador Adam, con un LR de 0.001 y un b [0.900 – 0.999]

c: Data augmentation

P14

Completa el fragmento de código para implementar una conexión residual (skip connection) simple en Keras (estilo ResNet). La entrada x tiene forma (None, 64, 64, 128). Explica en 2-3 líneas qué problema resuelve esta arquitectura.

```
def residual_block(x, filters=128):
    shortcut = x
```



```
x = Conv2D(filters, (3,3), padding='same')(x)
x = BatchNormalization()(x)
x = Activation('relu')(x)
x = Conv2D(filters, (3,3), padding='same')(x)
x = BatchNormalization()(x)
# Completa la conexion residual:
x = x + shortcut
x = Activation('relu')(x)
return x
```

Respuesta:

Esta arquitectura resuelve el problema de desvanecimiento de gradiente al permitir que la información y los gradientes pasen directamente entre capas. Esto facilita el entrenamiento y mejora la precisión